基于 Nexent 的政务资产认知与可进化决策智能体

开发设计文档（第一、二章）

第十一届华为 ICT 大赛中国创新赛 · 赛题 3

基于华为 ModelEngine Nexent 打造可进化决策智能体

稿件日期：2026 年 10 月 31 日。学校、队名、成员等信息按官方模板填写。

1 项目概述

1.1 背景与痛点

政务服务领域积累了大量公开资料：办事指南、政策问答、政策解读、收费目录表格和扫描版政策附件。以居民身份证申领、换领、补领为例，同一事项的依据分散在不同部门、不同年份、不同格式的文件中，长期处于“能下载、难利用”的沉睡状态。群众咨询和窗口复核都需要把这些资料拼起来，并说明每个结论出自哪里。本项目在真实公开资料上归纳出以下五类痛点。

（1）多模态异构，资料难以联通。收费依据的文号记在 Excel 收费目录的单元格里，收费分支写在财政部通知的网页正文中，历史便民措施只存在于扫描版 PDF。只做文本检索，难以把三类资料连成一条依据链。

（2）跨文档口径复杂，容易答错分支。首次申领居民身份证的工本费自 2018 年 4 月 1 日起停征（财税〔2018〕37 号），换领仍按 2007 年通知每证 20 元（财综〔2007〕34 号）。回答“换领收多少钱”必须同时读两份文件，并区分首次申领、换领、补领等分支。

（3）知识持续变化，旧依据仍需追溯。河南身份证办理时限由 2024 年措施的 25 个自然日调整为 2026 年措施的 15 个工作日。两者单位不同，不能直接相减；新资料到来时，旧依据也要保留，以便核对历史办件。

（4）标注稀缺，属于典型低资源场景。政务领域缺少成规模的标注数据，而条款中的对象、地区、期限和例外又必须完全准确，难以依靠大规模标注训练专用模型。

（5）可追溯要求高。面向群众的答复必须给出原文出处；资料不足或现行效力未确认时，系统应当明确停止，而不是猜测。

1.2 项目目标与定位

本项目基于华为 ModelEngine Nexent 平台，构建政务领域的资产认知与可进化决策智能体。以河南、南京、北京等地居民身份证业务的公开资料为试点，目标是：

- **多模态资产统一识别与标识：**HTML、Excel、扫描 PDF 统一登记原件哈希、修订版本和精确定位，并转为可检索、可引用的资产单元。
- **低资源半自动本体构建：**从少量原文语法种子生成候选类型、关系和条件，人工确认结构后成为可执行的推理计划，并随资料变化持续演化。
- **检索-推理双驱动执行流：**借助 Nexent 的主控与子 Agent 编排、MCP 工具的确定性执行，完成跨文档多跳推理，每一步都可溯源。
- **可复用 Skill 工作流模板：**把验证过的编排模式沉淀为参数化模板，新事项、新地区按规格即可快速部署。

系统服务三类用户：咨询群众获得带原文出处的答复；窗口工作人员按固定知识版本复核和交接；资料维护者登记来源、审核更新候选、管理知识版本。

1.3 主要创新点

（1）多模态资产统一标识与跨格式推理。每份原件以 SHA-256 标识，修订与定位分开记录：HTML 记到段落和条文，Excel 记到单元格和行，扫描 PDF 记到 PDF 页码及左右半页。河南试点中，Excel、HTML、扫描 PDF 三种格式的 17 处定位共同进入同一条四节点推理计划，表格提供规范文号，网页提供收费分支，扫描件提供历史服务条件。

（2）低资源半自动本体构建与演化。不依赖大规模标注：少量原文语法种子从完整条款中抽取候选，人工只需确认结构；确认后的关系成为带类型、带来源、带依赖的执行计划。版本不可变、可一键回退，来源发生变化时旧结果自动阻断。北京、南京、河南三地分别完成了新类型或新关系的构建与执行。

（3）检索-推理双驱动与确定性核验。模型只负责任务调度和答复组织；检索、本体计划执行、引文逐字核对、数值与单位核对都由 MCP 工具完成。任何环节不通过即停止作答，并说明缺少什么依据。

（4）可复用 Skill 工作流模板与自主更新。把“主控—检索—核验”的编排抽象为分层模板，由 profile 规格生成 Skill 和主控协议，河南链路的 Skill 可由模板逐字复现。主控心跳与官方来源观察发现新资料后，交由整理和核验子 Agent 生成待审更新候选。

1.4 当前完成情况

截至 2026 年 10 月 30 日，主要能力的实现与验证结果见表 1-1。其中南京、河南两条推理链、河南自主更新和自由提问问答均在本机 Nexent v2.7.0 上实际运行。

表 1-1 主要能力与验证结果

能力	实现与验证结果
多模态冻结语料	7 份官方原件（HTML、Excel、扫描 PDF）整理为 581 个检索单元，原件 SHA-256 全部核对一致；资料目录累计登记 79 份文档、186 个修订（10 月 18 日快照）
跨文档多跳推理（南京）	本体控制的三步依赖计划在 Nexent 主控与两个子 Agent 中实跑，13 项验收全部通过，7 次模型启动，耗时约 14.6 秒
三模态归档推理（河南）	Excel、HTML、扫描 PDF 共 17 处定位进入四节点计划，Nexent 实跑 15 项验收全部通过，7 次模型启动，耗时约 13.2 秒
自由提问问答	Nexent 智能体通过检索、核验两个 MCP 工具作答；界面实测跨文档收费问题 4.07 秒给出带两处引用的答复，询问“现在的收费”时按规则停止作答
本体半自动构建（北京）	从归档办事指南生成新类型和新关系，人工确认后在本地执行 6 个虚构场景，随后回退
自主更新（河南）	心跳在自然到期时发现新归档资料，整理与核验子 Agent 生成 1 条待审候选，正式版本未被改动
运行保障	主控进程退出后由计划任务约 4 秒恢复监听；官方来源观察完成首次采集并形成待审修订
工程交付	公开仓库以 MIT 许可开源；工程包解压到新目录后可自行重建，包内 392 项离线测试通过

1.5 应用价值与资产激活路径

本项目把沉睡的公开资料逐步激活为可用的决策依据，路径为：原件登记与定位 → 检索单元与本体候选 → 人工确认的可执行计划 → 带出处的答复与更新候选。在这条路径上，三类用户分别获益：

- **群众**：直接得到带原文出处的答复；资料不足时会被明确告知原因和缺少的依据，不会拿到可能错误的结论。
- **工作人员**：答复绑定资料版本和定位，便于复核与交接；新旧政策的差异以待审候选形式呈现，审核后再生效。
- **维护者**：新增事项或地区时复用 Skill 模板和 MCP 工具，只需配置资料来源和推理计划，不必从零搭建智能体。

1.6 当前边界

本文所述结果均来自冻结的公开历史资料。系统答复统一标注“历史归档解释、未核定现行效力”，不构成政策发布。业务效果的独立评测（30 题配对比较）和低资源构建效率对照正在进行，结果将在效果验证部分给出；扫描件目前使用已有的署名 AI 转录，人工复核正在进行。

2 整体方案设计

2.1 设计原则

- **来源可溯**：每条结论绑定原件哈希、修订和定位，引文必须逐字出自原文。
- **人工把关**：新的本体结构和新的资料版本先作为待审候选，经人工确认才生效；结构确认不等于业务批准。
- **确定性优先**：检索、计划执行、数值与单位核对等可以计算的部分交给工具，模型不自行补全事实。
- **失败即停**：来源缺失、版本变化、问题超出范围或核验不通过时停止作答，并说明原因。
- **最小权限与隐私**：工具只接受限定输入，不接收身份证号等个人信息；凭据只保存在本机私有目录。

2.2 总体架构

系统分为五个功能层和一组运行保障机制（图 2-1）。数据自下而上被识别、组织为知识，经工具执行和智能体编排，最终以带出处的答复呈现给用户；用户问题和更新任务则自上而下逐层下发。

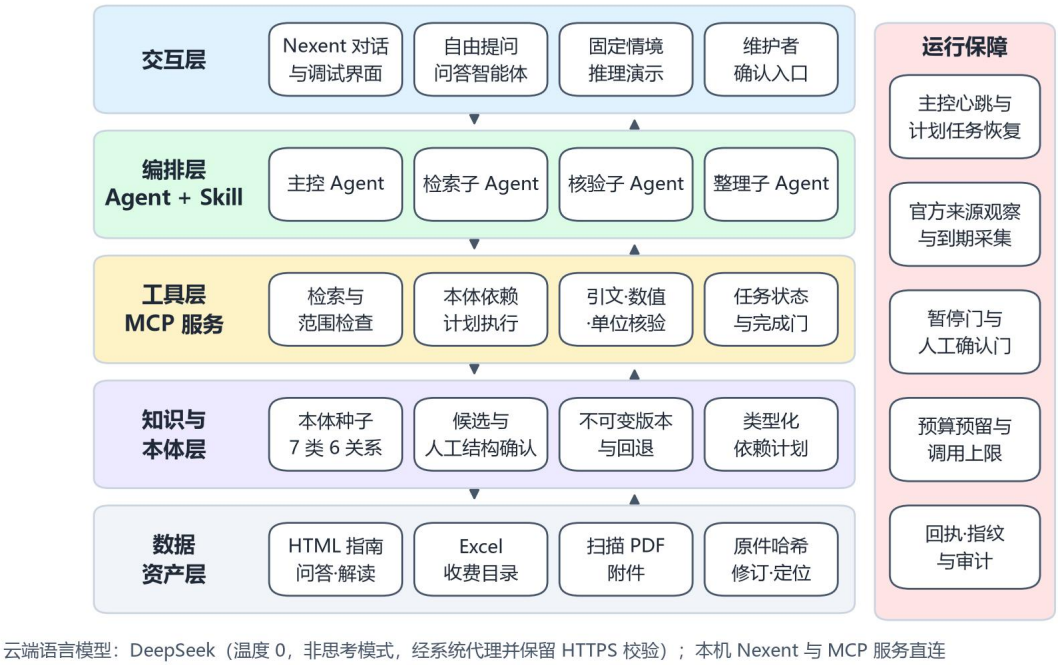


图 2-1 系统总体架构

表 2-1 各层组成与实现

层次	主要组成	实现要点
数据资产层	官方 HTML、Excel 收费目录、扫描 PDF	采集前检查 robots 规则，核对原件 SHA-256；按页面选择器提取段落和条文，Excel 只读字面值、不执行公式，扫描页保留页码与左右半页定位
知识与本体层	本体种子、候选、版本库	种子含 7 类实体（事项、条件、材料、部门、程序、规范条款、资产）和 6 类关系（需要、适用于、办理部门、包含步骤、对齐、证据支持）；候选经人工确认后成为不可变版本，可回退
工具层	MCP 服务	基于 FastMCP 的 SSE 服务，使用专用 Bearer 令牌、Host 与 Origin 白名单，启动时记录代码指纹，代码变更后拒绝继续服务
编排层	Nexent 主控与子 Agent、Skill	主控按 Skill 规定的顺序调度子 Agent，每个角色只能使用指定工具，并设有步数上限
交互层	Nexent 对话与调试界面	群众或工作人员用自然语言提问，答复包含结

层次	主要组成	实现要点
		论、逐条引用、未知项和状态说明
运行保障	心跳、计划任务、来源观察	主控心跳与计划任务恢复，官方来源到期采集，暂停门与人工确认门，调用预算与回执审计

2.3 核心执行流程

2.3.1 检索-推理双驱动查询流程

查询流程如图 2-2 所示。主控 Agent 读取 Skill 后先做范围检查：问题含个人信息、涉及试点范围以外的地区，或询问“现在、现行”的规定时，直接停止并说明原因。范围内的问题进入检索，工具取回前 5 条证据；本体推理链还会检查来源是否暂停或已变化。推理阶段，固定业务情境执行已确认的本体依赖计划；自由提问则由模型在规则约束下组织答复。最后，核验工具逐条检查引文是否逐字出自检索到的原文、答复中的数字和天数单位是否被引用，不通过即改为停止作答。

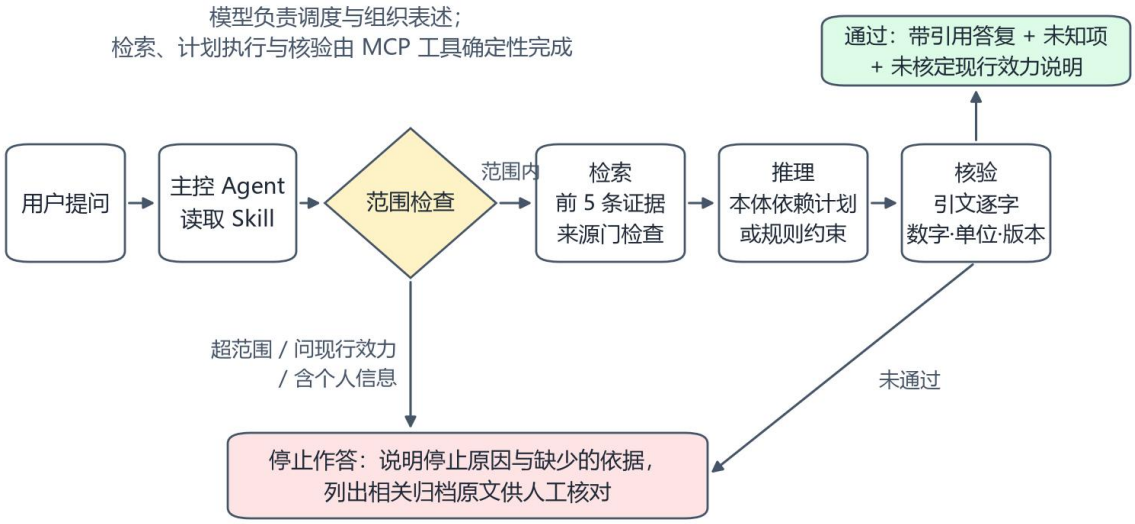


图 2-2 检索-推理双驱动查询流程

以南京试点为例，系统需要同时读取两份官方问答：周期问答给出省内 20 个工作日、省外户籍增加 5 个工作日，旧证问答说明“未超期的旧身份证可以继续使用”。本体计划依次执行三步：计算办理周期、取旧证有效区间的交集、比较二者覆盖关系，在虚构情境（省外户籍、旧证剩余 22 个工作日）下得出“不

能确认旧证可覆盖整个办理周期”的结论。缺少任一份文件时，结论自动降为未知。

2.3.2 知识更新与本体演化流程

更新流程如图 2-3 所示。主控心跳和官方来源观察按到期时间采集资料，发现新原件后记录哈希与修订；整理子 Agent 分别读取新旧资料的完整视图并提交结构化差异，核验子 Agent 独立复核证据；结果以待审候选形式保存，不继承旧批准，也不自动发布。人工确认后，新版本才被激活；版本不可变，可随时回退。本体结构的变化（类型、关系、执行语义）与资料内容的变化（修订、差异候选）分开管理。

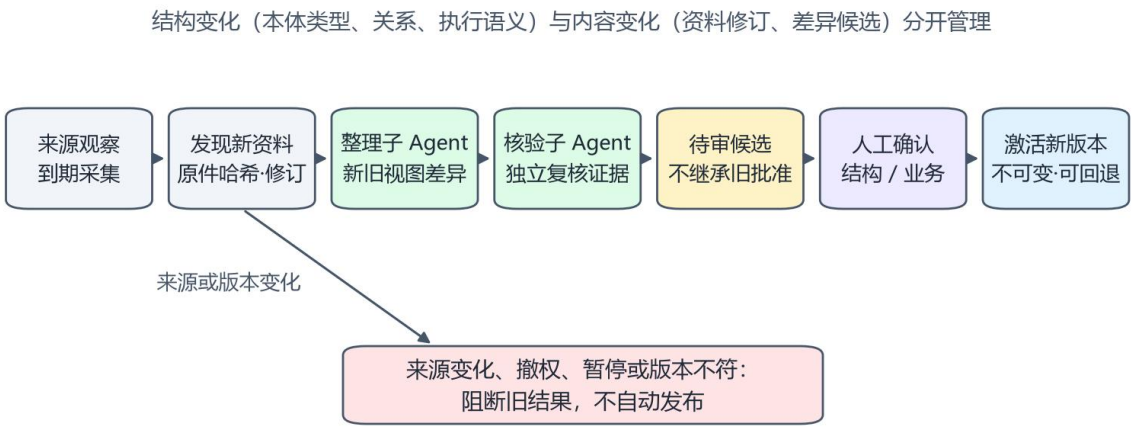


图 2-3 知识更新与本体演化流程

2.4 智能体设计

系统在 Nexent 上配置三组智能体（表 2-2）。所有智能体使用 DeepSeek 官方模型 deepseek-flash，温度 0，关闭思考模式，每步输出不超过 1024 tokens；演示期间均为禁用、未发布的草稿，由受控接口或配置页调试对话运行。

表 2-2 智能体与职责

智能体组	角色	可用工具	关键约束
自由提问	问答助手（主）	检索、核验	最多 6 步；只依据检索证据作答；核验不通过即停止
本体推理	主控	开启任务、读取状态、完成交付	最多 6 步；只有持久化的核验阶段通过后才能交付
本体推理	检索子 Agent	取回绑定来源的完整原文	最多 3 步；每个任务只调用一次

智能体组	角色	可用工具	关键约束
本体推理	核验子 Agent	执行已确认的本体依赖计划	最多 3 步；使用工具返回的实际参数和依赖轨迹
知识更新	主控	读取阶段状态、完成	先调用整理、后调用核验；完成门通过才返回
知识更新	整理子 Agent	读取新旧视图、提交差异	最多 4 步；新旧资料各读一次完整视图
知识更新	核验子 Agent	读取新旧视图、提交复核	最多 4 步；独立核对证据与候选

2.5 MCP 工具与 Skill 分层编排

工具按职责拆分，每个工具只做一件事（表 2-3）。每次调用都会重新检查服务代码指纹；本体推理工具还会复查来源门和已确认的本体版本。

表 2-3 MCP 服务与工具

服务	工具	作用
本体推理服务	open_query	按固定情境开启任务，返回任务编号
本体推理服务	retrieve	取回本体绑定来源的完整原文选段
本体推理服务	verify	执行已确认的本体依赖计划，记录逐跳依据
本体推理服务	state / finalize	读取持久阶段并复查来源与版本；重新执行并原样返回持久答复
自由提问服务	frozen_retrieve	范围检查，返回前 5 条证据和作答规则
自由提问服务	frozen_verify	核对引文、数字和天数单位，不通过即改为停止
知识更新服务	get / submit / review / state / finish	读取新旧视图，提交差异与复核，推进阶段并完成

Skill 采用分层编排（表 2-4）。编排层和协议层已沉淀为参数化模板：新部署只需填写情境、Agent 名称和证据说明，由渲染工具生成 Skill 与主控协议；执行层的来源适配和计划算子仍需按事项开发。

表 2-4 Skill 分层与复用方式

层次	内容	复用方式
平台层	主控与检索、核验子 Agent，模型参数、步数上限	统一接线脚本创建，profile 只换名称
编排层	读 Skill → 开任务 → 检索 → 核验 → 读状态 → 完成	Skill 模板固定

层次	内容	复用方式
协议层	可执行动作格式、子 Agent 调用示例、禁止重复与重试	主控协议模板固定
工具层	5 个本体推理工具及其门禁检查	共用服务，按 profile 分派
执行层	来源适配器、已确认依赖计划、领域算子	按事项开发

2.6 数据与安全设计

- **数据范围：**只使用公开的官方资料，标记为公开数据；演示使用虚构情境，不采集居民证件号或真实个人回答。
- **凭据与网络：**模型凭据通过环境变量或本机私有目录提供，不写入仓库；MCP 服务使用专用令牌；云端请求沿用系统代理并保留 HTTPS 证书校验，本机 Nexent 与 MCP 服务直连。
- **状态门：**答复保持“未审核暂停、现行效力未知、未正式批准”的状态标注；新候选不自动发布，旧批准不被继承。
- **预算与失败处理：**调用前预留预算并设上限；模型、工具或来源出错时停止，不重试业务请求，失败记录完整保留。

2.7 部署与运行环境

表 2-5 运行环境

组件	版本与配置
智能体平台	Nexent v2.7.0（Docker 部署）：配置服务 5010、运行服务 5014、Web 界面 3000
语言模型	DeepSeek 官方 API，deepseek-flash；温度 0，非思考模式
MCP 服务	本体推理 8785、自由提问 8786、知识更新 8784，均仅监听本机，通过 host.docker.internal 供容器访问
运行环境	Windows 11、Docker Desktop（WSL2）、Python 3.12，依赖版本锁定
交付方式	公开仓库（MIT 许可）；打包脚本生成工程包并核验散列，Agent 配置以平台导出 JSON 提供